

PCA 简介:

PCA 是一种线性降维方法，它的目标是通过某种线性投影，将高维的数据映射到低维空间中，并期望在所投影的维度上数据的信息量最大（方差最大），以此使用较少的数据维度，同时保留较多的原数据点的特性。

PCA 降维的目的，就是为了尽量保证“信息量”不丢失的情况下，对原始特征进行降维，也就是尽可能将原始特征往具有最大投影信息量的维度上进行投影，将原始特征投影到这些维度上，使降维后信息量最小。

输入： n 维样本集 $X = (x_1, x_2, \dots, x_m)$ ，维度： $m \times n$ ， m 为样本数， n 为特征数
 k 为要降维到的维数。每一特征都为随机变量。

输出：降维后的样本集 Y

PCA 算法流程：

1. 对所有样本进行中心化： $x_i = x_i - \frac{1}{m} \sum_{j=1}^m x_j$ ， x_i ：第 i 个样本，维度： $1 \times n$ ，
计算每个特征的平均值，并从相应列的每一行中减去该平均值。得到 X_meaned
2. 计算协方差矩阵： $C = \frac{1}{m-1} (X_meaned)^T X_meaned$ ，维度： $n \times n$ 。包含的是
特征之间的协方差，对角线为特征方差。
3. 求出协方差矩阵的特征值及对应的特征向量。 $(n \times n)$
4. 将特征向量按对应特征值大小从左到右按列排成矩阵，取前 k 列组成矩阵
 $P(n \times k)$
5. $Y = XP$ 即为降维到 k 维后的数据。